

Impactos da Seleção de Instâncias na Localidade e Explicabilidade

Karina Batista da Silva

UFMG

Belo Horizonte, Brasil

karinabatista12@ufmg.br

Davila de Carvalho Meireles

UFMG

Belo Horizonte, Brasil

davila.meireles@gmail.com

Samai Soares Pereira

UFMG

Belo Horizonte, Brasil

samaisoares@gmail.com

Resumo

Modelos baseados em Transformers apresentam elevado desempenho em tarefas de classificação de texto. Paralelamente, técnicas de Seleção de Instâncias (*Instance Selection* – IS) têm sido utilizadas para reduzir conjuntos de treinamento por meio da remoção de exemplos redundantes ou ruidosos, diminuindo o custo computacional sem comprometer significativamente a eficácia dos modelos. Entretanto, ainda não está claro como a aplicação dessas técnicas influencia a organização semântica do espaço aprendido pelos modelos e, consequentemente, sua explicabilidade.

Este trabalho investiga os impactos dos métodos de Seleção de Instâncias E2SC e biO-IS na localidade semântica e no potencial explicativo de modelos BERT aplicados à classificação de textos. Para isso, foram treinados modelos utilizando o conjunto AGNews original e versões reduzidas obtidas por estes métodos de IS. Em seguida, foram extraídos os embeddings do token CLS da última camada do BERT para as instâncias de teste. A partir dessas representações, foram calculadas métricas de similaridade média e entropia de classes em vizinhanças definidas por k-Nearest Neighbors (kNN) e foram geradas nuvens de palavras baseadas nas vizinhanças das instâncias para apoiar a análise qualitativa da explicabilidade. Os resultados indicam um efeito dissociado da IS sobre a localidade: a similaridade aumenta nos dois métodos, mas a concentração em regiões de alta homogeneidade cresce apenas com o biO-IS. Isso sugere que a remoção de ruído, e não apenas de redundância, contribui para a estrutura semântica do espaço.

1 Introdução

O avanço dos modelos baseados em Transformers revolucionou o Processamento de Linguagem Natural (PLN), permitindo alcançar elevados níveis de desempenho em tarefas como classificação de texto. Modelos como BERT [4] e RoBERTa [5] são amplamente utilizados devido à sua capacidade de aprender representações contextuais que capturam relações semânticas complexas. Entretanto, o treinamento e a utilização desses modelos demandam elevados recursos computacionais e frequentemente resultam em modelos de difícil interpretação.

Com o crescimento do uso desses modelos em aplicações reais, a eficiência computacional e a explicabilidade passaram a ser cada vez mais importantes. Nesse contexto, técnicas de Seleção de Instâncias (*Instance Selection* – IS) têm sido utilizadas para reduzir conjuntos de treinamento por meio da remoção de exemplos redundantes ou ruidosos. Trabalhos recentes demonstram que métodos como E2SC e biO-IS podem reduzir significativamente o tamanho dos datasets e o tempo de treinamento sem causar perdas relevantes de desempenho.

Além disso, a área de Inteligência Artificial Explicável (*Explainable Artificial Intelligence* – XAI) busca tornar as decisões dos modelos mais compreensíveis. Em tarefas de classificação de texto,

abordagens baseadas em localidade assumem que instâncias semanticamente próximas compartilham características semelhantes e, portanto, podem fornecer explicações mais consistentes sobre as decisões produzidas pelo modelo. Estudos recentes indicam que regiões do espaço vetorial caracterizadas por alta similaridade e baixa entropia de classes tendem a produzir explicações mais intuitivas e informativas.

Embora os métodos de IS tenham sido originalmente desenvolvidos com foco em eficiência computacional, não está claro se a remoção de ruído e redundância também influencia a organização semântica do espaço representacional aprendido pelos Transformers, favorecendo a formação de localidades mais homogêneas e potencialmente mais explicáveis.

Desta forma, este trabalho investiga os impactos dos métodos E2SC e biO-IS na localidade semântica e no potencial explicativo de modelos BERT aplicados à classificação de texto. Para isso, são comparados modelos treinados com o conjunto original de treinamento e com versões reduzidas obtidas por Seleção de Instâncias. A análise é realizada a partir dos embeddings do token CLS da última camada do BERT, utilizando métricas de similaridade e entropia calculadas sobre vizinhanças definidas por k-Nearest Neighbors (kNN), além de avaliações qualitativas baseadas em nuvens de palavras.

A principal contribuição deste trabalho consiste em investigar se técnicas de Seleção de Instâncias podem atuar não apenas como método de redução de custo computacional, mas também como ferramenta capaz de melhorar a estrutura semântica do espaço dos modelos e, consequentemente, favorecer a geração de explicações mais interpretáveis.

Especificamente, este trabalho busca responder às seguintes perguntas de pesquisa:

- **PP1:** A aplicação dos métodos de Seleção de Instâncias preserva a eficácia dos modelos, apesar da redução do conjunto de treinamento?
- **PP2:** A Seleção de Instâncias altera a localidade semântica do espaço representacional, em termos de similaridade e homogeneidade das vizinhanças?
- **PP3:** O efeito sobre a localidade difere entre os métodos E2SC e biO-IS, e essa diferença é coerente com os mecanismos de cada método (remoção de redundância vs. remoção de ruído)?

2 Trabalhos Relacionados

A pesquisa aqui apresentada situa-se na interseção de três linhas de investigação: a Seleção de Instâncias para Classificação Automática de Texto, a explicabilidade baseada em localidade semântica e a caracterização do espaço representacional de modelos baseados em Transformers.

2.1 Seleção de Instâncias em Classificação de Texto

A Seleção de Instâncias (IS) tem como objetivo reduzir o conjunto de treinamento pela remoção de exemplos redundantes ou ruidosos, diminuindo o custo computacional do treinamento sem comprometer a eficácia. Cunha et al. [3] propuseram o E2SC, um arcabouço baseado em estimativas de confiança produzidas por um classificador auxiliar para identificar instâncias redundantes em tarefas de classificação de texto baseadas em Transformers. Posteriormente, Cunha et al. [2] apresentaram o biO-IS, que combina a remoção de redundância com a remoção de ruído por meio de duas taxas independentes, alcançando reduções expressivas no tamanho dos conjuntos e acelerações de treinamento de até $2,46\times$ sem perda relevante de eficácia. Estes trabalhos estabelecem que a redução de dados, quando guiada por critérios de qualidade, preserva o desempenho dos modelos. Contudo, seu foco é a eficiência computacional, sem investigar como a remoção de instâncias afeta a organização semântica do espaço aprendido.

2.2 Explicabilidade baseada em Localidade

Na área de Inteligência Artificial Explicável (XAI), abordagens pioneiras baseadas em localidade, como o LIME [8], assumem que instâncias semanticamente próximas no espaço vetorial compartilham características e, portanto, fornecem explicações mais consistentes [1]. Soares [9] investigou empiricamente o papel da localidade na explicabilidade de tarefas de classificação de texto, caracterizando vizinhanças por meio de métricas de similaridade média e entropia da distribuição de classes, calculadas com o algoritmo k-Nearest Neighbors (kNN) sobre embeddings do BERT. A autora demonstrou que localidades mais homogêneas (alta similaridade e baixa entropia) geram nuvens de palavras mais compreensíveis e fiéis à decisão do modelo. O presente trabalho adota diretamente a metodologia de caracterização de localidade proposta por Soares [9], estendendo-a para avaliar o efeito da Seleção de Instâncias. Além da homogeneidade, um desafio central em métodos locais é a sua estabilidade. Conforme apontado por trabalhos recentes como o de Rahulamathavan et al. [7], explicações baseadas em vizinhança podem ser sensíveis a pequenas perturbações no espaço de representação, o que torna a avaliação da robustez dessas localidades um fator crítico para a confiabilidade em XAI.

2.3 Lacuna e Posicionamento

A literatura mostra, por um lado, que a IS reduz dados preservando eficácia [2] e, por outro, que a homogeneidade da localidade favorece a explicabilidade [9]. Permanece em aberto a relação entre essas duas frentes: se a aplicação prévia de métodos de IS altera ativamente a topologia do espaço latente dos Transformers, concentrando instâncias em regiões de alta homogeneidade. Este trabalho aborda essa lacuna, posicionando a Seleção de Instâncias não apenas como ferramenta de eficiência, mas como possível otimizador da estrutura semântica do espaço representacional.

3 Metodologia

3.1 Dataset

Os experimentos foram conduzidos utilizando o conjunto de dados AGNews [11], composto por notícias distribuídas em quatro categorias temáticas: World, Sports, Business e Sci/Tech. Foram utilizados os splits previamente definidos pelo benchmark, contendo conjuntos independentes de treinamento, validação e teste.

A divisão utilizada corresponde ao fold 0, contendo:

- Treinamento: 91872 instâncias;
- Validação: 25520 instâncias;
- Teste: 10208 instâncias.

Os mesmos conjuntos de validação e teste desta divisão foram mantidos para todos os experimentos, garantindo que as comparações fossem realizadas sobre as mesmas instâncias.

3.2 Seleção de Instâncias

A Seleção de Instâncias (IS) foi empregada com o objetivo de reduzir o conjunto de treinamento por meio da remoção de exemplos redundantes e potencialmente ruidosos. Foram avaliados dois métodos recentes da literatura: E2SC e biO-IS, ambos desenvolvidos especificamente para tarefas de Classificação Automática de Texto.

Antes da aplicação dos algoritmos de seleção, os documentos foram representados utilizando TF-IDF (*Term Frequency – Inverse Document Frequency*). Foi utilizada a implementação `TfidfVectorizer` da biblioteca Scikit-Learn [6], com remoção de *stopwords* em inglês, unigramas, normalização L2, ponderação TF-IDF suavizada e frequência sublinear, com limite máximo de 50.000 atributos. Os parâmetros correspondentes na biblioteca foram *n-gram range* (1,1), *smooth idf* ativado e *sublinear tf* ativado.

O método E2SC (*Effective, Efficient and Scalable Confidence-Based Instance Selection*) tem como objetivo principal identificar e remover instâncias redundantes. O algoritmo utiliza estimativas de confiança produzidas por um classificador auxiliar (*weak classifier*) para selecionar exemplos representativos e reduzir a redundância presente no conjunto de treinamento.

Já o método biO-IS (*Noise-Oriented and Redundancy-Aware Instance Selection*) realiza a remoção conjunta de instâncias redundantes e exemplos potencialmente ruidosos. O método utiliza duas taxas independentes de redução: uma associada à remoção de redundância e outra associada à remoção de ruído. Dessa forma, busca-se produzir conjuntos de treinamento mais compactos e semanticamente consistentes.

Em ambos os métodos, o classificador auxiliar utilizado para estimar as medidas de confiança foi uma Regressão Logística (*Logistic Regression*) com os parâmetros padrão da biblioteca Scikit-Learn.

Nos nomes dos conjuntos reduzidos, o prefixo *a* corresponde à taxa de redução de redundância (β) e o prefixo *t* à taxa de redução de ruído (γ). No conjunto E2SC (a25), aplicou-se $\beta = 25\%$ de redução de redundância. No conjunto biO-IS (a25_t50), aplicaram-se $\beta = 25\%$ de redução de redundância e $\gamma = 50\%$ de redução de ruído.

A Tabela 1 apresenta a quantidade de instâncias presentes em cada cenário experimental após a aplicação dos métodos de Seleção de Instâncias.

Tabela 1: Redução do conjunto de treinamento após a aplicação dos métodos de Seleção de Instâncias.

Método	Instâncias	Percentual
Baseline	91872	100%
E2SC	76560	83,3%
biO-IS	72191	78,6%

3.3 Caracterização da Localidade

A localidade foi caracterizada seguindo a metodologia de Soares [9]. Para cada instância do conjunto de teste, recuperaram-se seus $k = 30$ vizinhos mais próximos por meio do algoritmo k-Nearest Neighbors (kNN) com distância do cosseno. O kNN foi ajustado sobre o conjunto de treinamento de cada cenário (reduzido, nos casos com IS) e consultado sobre o conjunto de teste completo. Para cada vizinhança, calcularam-se duas métricas: a entropia de Shannon da distribuição de classes dos 30 vizinhos (medida de homogeneidade) e a distância média aos vizinhos (medida de similaridade). Ambas as métricas foram normalizadas (*min-max*) por cenário para a construção dos mapas de homogeneidade. A partir das mesmas vizinhanças, geraram-se nuvens de palavras com os 25 termos mais frequentes, para a análise qualitativa da explicabilidade.

4 Projeto Experimental

A Figura 1 ilustra o pipeline metodológico e o projeto experimental adotados nesta pesquisa. A partir do conjunto AGNews, três cenários de treinamento são derivados (Baseline, E2SC e biO-IS), cada um produzindo um modelo BERT treinado de forma independente. Os três modelos são então avaliados sobre o mesmo conjunto de teste, e suas representações são caracterizadas sob o mesmo protocolo de localidade, garantindo a comparabilidade entre os cenários.

4.1 Treinamento dos Modelos

Após a etapa de Seleção de Instâncias, foram treinados modelos de classificação de texto baseados na arquitetura BERT (*Bidirectional Encoder Representations from Transformers*). Foram considerados três cenários experimentais: um modelo baseline treinado com o conjunto original de treinamento, um modelo treinado com o conjunto reduzido pelo método E2SC e um modelo treinado com o conjunto reduzido pelo método biO-IS.

Todos os modelos utilizaram como base o modelo pré-treinado *bert-base-uncased*, disponível na biblioteca Hugging Face Transformers [10]. O processo de treinamento consistiu em realizar o *fine-tuning* do modelo para a tarefa de classificação de notícias do conjunto AGNews, composto por quatro classes temáticas.

Os principais hiperparâmetros utilizados durante o treinamento são apresentados na Tabela 2.

O treinamento foi realizado utilizando a biblioteca PyTorch em conjunto com a biblioteca Transformers. Durante cada época, os pesos do modelo foram atualizados a partir do conjunto de treinamento por meio do algoritmo de retropropagação do erro (*backpropagation*). O conjunto de validação foi utilizado para monitorar a perda (*loss*) e as métricas de desempenho ao longo das épocas de treinamento. Ao final do treinamento, os modelos foram avaliados




Figura 1: Pipeline metodológico e projeto experimental. A partir do conjunto AGNews, derivam-se três cenários de treinamento (Baseline, E2SC e biO-IS), cada um gerando um modelo BERT independente. Os três modelos são avaliados sobre o mesmo conjunto de teste, e a localidade é caracterizada por kNN ($k = 30$, cosseno).

Tabela 2: Hiperparâmetros utilizados no treinamento dos modelos.

Parâmetro	Valor
Modelo Base	bert-base-uncased
Batch Size (treino/avaliação)	32 / 64
Learning Rate	2×10^{-5}
Número de Épocas	2
Comprimento Máximo	256 tokens
Precisão	FP16
Otimizador	AdamW
Número de Classes	4

utilizando o mesmo conjunto de teste, garantindo a comparabilidade dos resultados entre os cenários Baseline, E2SC e biO-IS.

4.2 Extração dos Embeddings CLS

Após o treinamento dos modelos, foi realizada a extração das representações vetoriais das instâncias do conjunto de teste. Para garantir a comparabilidade entre os cenários experimentais, o mesmo conjunto de teste foi utilizado para os modelos Baseline, E2SC e biO-IS.

Cada modelo foi carregado a partir dos pesos obtidos após o fine-tuning sobre seu respectivo conjunto de treinamento. Em seguida, as instâncias de teste foram tokenizadas utilizando o tokenizer do modelo *bert-base-uncased*. Para cada documento, foi extraído o vetor associado ao token especial [CLS] na última camada oculta do BERT.

O token [CLS] é utilizado pelo BERT como uma representação agregada da sequência de entrada, sendo empregado pela camada classificadora para produzir a predição final. Assim, seu embedding na última camada foi adotado como representação do documento no espaço vetorial aprendido pelo modelo. Formalmente, para cada lote de documentos, os embeddings foram obtidos a partir de `last_hidden_state[:, 0, :]`, que seleciona o vetor correspondente ao token [CLS]. Como foi utilizado o modelo `bert-base-uncased`, cada embedding possui dimensão 768.

Os embeddings, rótulos e textos de cada instância de teste foram armazenados em arquivos no formato *pickle* (.pkl), preservando a mesma ordem das instâncias em todos os cenários. Cada registro contém o texto, o rótulo real, o vetor de 768 dimensões do token [CLS] e a predição do modelo. A manutenção da mesma base de teste e da mesma ordem das instâncias em todos os arquivos é essencial para permitir a comparação direta entre os espaços representacionais produzidos pelos modelos treinados com e sem Seleção de Instâncias.

5 Resultados e Análises

Esta seção apresenta os resultados em três dimensões complementares: eficácia e eficiência (5.1), impacto na localidade semântica (5.2), e análise qualitativa da explicabilidade via nuvens de palavras (5.3). As análises de *ablation* avaliam o efeito da Seleção de Instâncias por região de homogeneidade e o contraste entre os métodos E2SC e biO-IS.

5.1 Eficácia e Eficiência

A Tabela 3 consolida as métricas de eficácia (acurácia e Macro-F1, calculadas sobre o conjunto de teste) e de eficiência (percentual de redução do treino). Os modelos treinados com Seleção de Instâncias mantiveram desempenho equivalente ou superior ao *baseline*, apesar da redução de 17 a 21% do conjunto de treinamento. Esse resultado corrobora a literatura [2], confirmando que a remoção de redundância e ruído não compromete a eficácia. O ganho de eficiência computacional correspondente, com *speedup* de até 2,46×, é documentado por Cunha et al. [2].

Tabela 3: Eficácia (teste) e redução do treino nos três cenários.

Modelo	Treino	Redução	Acurácia	Macro-F1
Baseline	91872	–	0,944	0,945
E2SC	76560	16,7%	0,960	0,962
biO-IS	72191	21,4%	0,956	0,957

5.2 Impacto na Localidade Semântica

5.2.1 Métricas globais e o efeito dissociado. A Tabela 4 apresenta as médias globais (valores brutos) sobre as 10.208 instâncias de teste. Observa-se um efeito dissociado da Seleção de Instâncias sobre as duas dimensões da localidade: ambos os métodos reduzem a distância média (vizinhos mais próximos, maior similaridade), mas aumentam a entropia média (vizinhanças mais heterogêneas em classe). O biO-IS produz a menor distância média (0,046), enquanto o E2SC apresenta o maior aumento de entropia (0,141).

Tabela 4: Métricas médias de localidade no conjunto de teste (valores brutos). Entropia menor indica maior homogeneidade; distância menor indica maior similaridade.

Cenário	Entropia média	Distância média
Baseline	0,041	0,070
E2SC	0,141	0,061
biO-IS	0,083	0,046

Esse resultado é coerente com a natureza dos métodos. A Seleção de Instâncias remove sobretudo redundância intraclasse, isto é, aglomerados de exemplos muito semelhantes da mesma classe. Com a remoção desses exemplos, diminui a quantidade de vizinhos “fáceis” da mesma classe ao redor de cada instância, e os 30 vizinhos passam a incluir proporcionalmente mais exemplos de outras classes, elevando a entropia. Ao mesmo tempo, o espaço torna-se mais compacto, o que reduz a distância média. O E2SC, voltado exclusivamente à redundância, apresenta esse efeito de forma mais acentuada.

5.2.2 Mapas de homogeneidade. A Figura 2 apresenta os mapas de homogeneidade (entropia *versus* distância) para os três cenários, separando instâncias corretamente classificadas (HIT) das incorretas (ERROR). Cada célula da grade 10×10 indica o número de instâncias de teste cuja vizinhança possui dada combinação de entropia e distância normalizadas; o canto inferior esquerdo corresponde à região de alta homogeneidade. Nos acertos (HIT), o biO-IS mantém forte concentração no canto de alta homogeneidade, enquanto o E2SC dispersa parte das instâncias para faixas de entropia superiores. Já nos erros (ERROR), as três configurações apresentam maior dispersão, o que reforça a associação entre vizinhanças heterogêneas e classificações incorretas.

5.2.3 Ablation: distribuição por faixa de entropia. A Tabela 5 detalha a distribuição das instâncias por faixa de entropia normalizada. Confirma-se, no nível populacional, o deslocamento observado nas médias: o *baseline* concentra 91,9% das instâncias na faixa de entropia muito baixa, contra 81,4% (biO-IS) e 71,3% (E2SC). A Seleção de Instâncias desloca parte das instâncias para faixas de entropia intermediária.

Tabela 5: Distribuição das instâncias de teste por faixa de entropia normalizada (%).

Faixa de entropia	Baseline	E2SC	biO-IS
Muito baixa [0,0–0,1)	91,9	71,3	81,4
Baixa [0,1–0,3)	4,9	19,7	12,8
Média [0,3–0,5)	1,7	6,5	3,7
Alta [0,5–0,7)	1,4	2,2	1,8
Muito alta [0,7–1,0]	0,1	0,3	0,2

5.2.4 Concentração no quadrante de alta homogeneidade. A pergunta de pesquisa indaga se a IS aumenta a concentração de instâncias no quadrante de alta homogeneidade (entropia e distância simultaneamente baixas, < 0,1 em ambas). A Tabela 6 mostra um resultado dependente do método: o biO-IS aumenta a concentração




Figura 2: Mapas de homogeneidade (entropia × distância) para os três cenários. Linha superior: acertos (HIT, em verde). Linha inferior: erros (ERROR, em laranja). O número em cada célula indica a quantidade de instâncias de teste; o canto inferior esquerdo representa alta homogeneidade (baixa entropia e baixa distância).

(70,5% contra 65,4% do *baseline*), confirmando a hipótese; e o E2SC a reduz (50,2%), contrariando-a. A explicação reside no critério conjunto: o quadrante exige baixa entropia e baixa distância. O biO-IS aprimora ambas, pois a remoção de ruído limpa as fronteiras de classe; o E2SC aprimora a distância mas eleva a entropia, perdendo o critério de homogeneidade. Esse resultado está alinhado à expectativa inicial do projeto, que previa efeito mais favorável para o biO-IS.

Tabela 6: Proporção de instâncias de teste no quadrante de alta homogeneidade (entropia < 0,1 e distância < 0,1).

Cenário	Alta homogeneidade (%)
Baseline	65,4
E2SC	50,2
biO-IS	70,5

5.2.5 Ablation: efeito por tipo de instância. Para compreender para quais instâncias a IS atua, analisaram-se as 16 instâncias selecionadas no estudo de Soares [9], organizadas em quatro grupos conforme a homogeneidade no *baseline* e o acerto do modelo. O

efeito é heterogêneo: nas instâncias originalmente pouco homogêneas mas corretamente classificadas (HIT-Low), a entropia caiu acentuadamente após a IS. Por exemplo, a instância de Sports “First lessons” passou de entropia 0,808 (*baseline*) para 0,000 (E2SC). Já as instâncias originalmente homogêneas (HIT-High) permaneceram com entropia nula nos três cenários, indicando que a IS preserva as vizinhanças já bem estruturadas. Observa-se, assim, um efeito de redistribuição: a IS homogeneiza a localidade das instâncias situadas em regiões ruidosas, sem degradar as que já eram homogêneas. A Tabela 7 consolida os valores de entropia das instâncias ilustrativas analisadas qualitativamente na Seção 5.3.

Tabela 7: Entropia das vizinhanças das instâncias ilustrativas (Figuras 3–6) nos três cenários, por grupo de homogeneidade no *baseline*.

Instância	Grupo	Base.	E2SC	biO-IS
“First lessons”	HIT-Low	0,808	0,000	0,646
“Chinese Train”	HIT-Low	0,671	0,184	0,368
“Prime time”	ERR-Low	1,000	0,703	0,306
“Baghdad”	HIT-High	0,000	0,000	0,000

5.3 Análise Qualitativa: Nuvens de Palavras

Para avaliar qualitativamente o impacto na explicabilidade, geraram-se nuvens de palavras a partir dos 30 vizinhos de cada instância, extraindo os 25 termos mais frequentes, conforme Soares [9]. As Figuras 3 a 6 comparam os três cenários para casos representativos.

Homogeneização da localidade (Sports, “First lessons”). Na Figura 3, a nuvem do *baseline* (entropia 0,808) é dominada por termos genéricos (*new, game, year, day*), sem foco temático claro. Após o E2SC (entropia 0,000), emergem termos inequivocamente esportivos (*team, season, play, series, coach*), evidenciando que a IS recompôs a vizinhança com exemplos efetivamente do domínio Sports. Este é o efeito previsto pela hipótese: a Seleção de Instâncias homogeneizou a localidade semântica.

Refinamento progressivo (Business, “Chinese Train”). Na Figura 4, os três cenários compartilham o tema industrial, mas a homogeneidade aumenta com a IS: do *baseline* ruidoso (entropia 0,671) para o E2SC concentrado em termos de indústria automotiva (entropia 0,184; *china, motor, toyota, nissan, hybrid, vehicle*).

Limite do método (Sci/Tech, “Prime time”). A Figura 5 ilustra uma nuance importante. Trata-se de uma instância rotulada Sci/Tech mas incorretamente classificada nos três cenários. A IS, em especial o biO-IS (entropia 0,306), tornou a vizinhança mais homogênea, porém em torno de um tema (*family, murder, police, killed*) que não corresponde ao rótulo real. Em outras palavras, a Seleção de Instâncias homogeneiza a localidade, mas, quando a instância está mal posicionada no espaço, essa homogeneização não corrige o erro: ela apenas torna a vizinhança equivocada mais coesa. Isso delimita o alcance do método como otimizador de explicabilidade.

Preservação do que já era homogêneo (World, “Baghdad”). Como controle, a Figura 6 mostra uma instância de alta homogeneidade no *baseline* (entropia 0,000). As nuvens dos três cenários são praticamente idênticas (*baghdad, iraq, iraqi, najaf, insurgent*), confirmando que a IS não degrada vizinhanças já bem estruturadas. A nuvem reproduz fielmente a apresentada por Soares [9], validando a fidelidade do *pipeline* ao método original.

5.4 Análise Exploratória: Estabilidade das Vizinhanças sob Perturbação

Além das perguntas de pesquisa centrais, conduziu-se uma análise exploratória complementar, não contemplada na metodologia original de Soares [9], sobre a estabilidade das vizinhanças sob perturbação dos embeddings. A motivação é que uma explicação baseada em localidade só é confiável se a vizinhança que a sustenta for robusta a pequenas variações na representação. Para cada uma das 16 instâncias analisadas na Seção 5.3, perturbou-se o embedding com ruído gaussiano de desvio-padrão igual a 5% da norma do vetor, repetindo o procedimento 20 vezes e recomputando a vizinhança de $k = 30$. A estabilidade foi medida pela sobreposição de Jaccard média entre o conjunto de vizinhos da representação original e o das representações perturbadas. Valores próximos de 1 indicam vizinhanças estáveis.

A Tabela 8 reporta a estabilidade média separando as instâncias por região de homogeneidade no *baseline*. O resultado é contraintuitivo: as regiões de baixa homogeneidade (Low) apresentaram

estabilidade superior às de alta homogeneidade (High) em ambos os métodos, o que contraria a expectativa de que vizinhanças mais homogêneas seriam mais robustas.

Tabela 8: Estabilidade média das vizinhanças (Jaccard) sob perturbação, por região de homogeneidade no *baseline*. Valores maiores indicam maior estabilidade.

Região	E2SC	biO-IS
Alta homogeneidade (High)	0,329	0,239
Baixa homogeneidade (Low)	0,555	0,523

A explicação reside na própria densidade das regiões homogêneas. Em uma vizinhança de alta homogeneidade, dezenas de vizinhos encontram-se a distâncias quase idênticas da instância consultada, sendo, portanto, intercambiáveis. Uma pequena perturbação basta para reordenar esses vizinhos quase equidistantes, alterando quais índices específicos compõem os $k = 30$ mais próximos e derrubando a sobreposição de Jaccard, ainda que o caráter da vizinhança (classe e conteúdo lexical) permaneça inalterado. Em regiões de baixa homogeneidade, os vizinhos são mais distintos entre si e a perturbação raramente altera o ranking, resultando em maior estabilidade de índice.

Essa interpretação é corroborada pela estabilidade dos termos das nuvens de palavras, isto é, a sobreposição dos termos mais frequentes antes e depois da perturbação, cuja diferença entre regiões é bem menor (E2SC: High 0,471 e Low 0,517; biO-IS: High 0,391 e Low 0,468). Embora os índices dos vizinhos em regiões de alta homogeneidade mudem bastante sob perturbação, o conteúdo semântico que eles carregam, e que efetivamente compõe a explicação, permanece estável. A instabilidade observada em High corresponde à rotatividade de índices entre exemplos equivalentes, e não à degradação da explicação. A métrica relevante para a robustez de explicações baseadas em localidade não é a identidade exata dos vizinhos, mas a estabilidade do conteúdo agregado da vizinhança. Por basear-se em execução única e em apenas 16 instâncias, a análise é exploratória e demanda confirmação com múltiplas sementes e um conjunto maior de exemplos.

6 Conclusão

Este trabalho investigou os impactos dos métodos de Seleção de Instâncias E2SC e biO-IS sobre a localidade semântica e a explicabilidade de modelos BERT aplicados à classificação de textos do conjunto AGNews. Estendendo a metodologia de caracterização de localidade de Soares [9], foram comparados três cenários (*baseline* com treino completo, E2SC e biO-IS) por meio de métricas de eficácia, homogeneidade (entropia), similaridade (distância) e análise qualitativa de nuvens de palavras.

Retomando as perguntas de pesquisa: quanto à PP1, confirmou-se que a Seleção de Instâncias preserva a eficácia, com acurácia e Macro-F1 equivalentes ou superiores ao *baseline* usando 17 a 21% menos dados; quanto à PP2, a IS altera a localidade de forma dissociada, aumentando a similaridade mas elevando a entropia média; e quanto à PP3, o efeito difere entre os métodos: o biO-IS aumenta a concentração em alta homogeneidade, enquanto o E2SC a reduz, comportamento coerente com a remoção de ruído realizada pelo primeiro.




Figura 3: Nuvens de palavras da vizinhança (kNN, $k = 30$) da instância de Sports “First lessons” nos três cenários. O E2SC homogeneiza a vizinhança (entropia 0,808 para 0,000), trazendo termos esportivos.




Figura 4: Instância de Business “Chinese Train”. A homogeneidade aumenta progressivamente com a IS (entropia 0,671 para 0,184 no E2SC).

Em maior detalhe, três conclusões se destacam. Primeiro, a Seleção de Instâncias preserva a eficácia: ambos os métodos mantiveram acurácia e Macro-F1 equivalentes ou superiores ao *baseline*, com redução de 17 a 21% do conjunto de treinamento. Segundo, a IS exerce um efeito dissociado sobre a localidade: aproxima os vizinhos, aumentando a similaridade, mas eleva a entropia média, por remover a redundância intraclasse que inflava a homogeneidade aparente. Terceiro, o efeito sobre a concentração no quadrante de alta homogeneidade depende do método: o biO-IS aumentou essa concentração (70,5% contra 65,4% do *baseline*), confirmando a hipótese de pesquisa, enquanto o E2SC a reduziu (50,2%). A diferença decorre da remoção de ruído realizada pelo biO-IS, que limpa as fronteiras de classe, ao passo que o E2SC atua apenas sobre redundância.

A análise qualitativa reforçou esses achados: a IS homogeneiza a vizinhança de instâncias situadas em regiões ruidosas, tornando as nuvens de palavras mais focadas no domínio da classe, e preserva as instâncias já homogêneas. Identificou-se, contudo, um limite: quando a instância está mal posicionada no espaço, a IS homogeneiza a vizinhança em torno de um tema incorreto, sem corrigir o erro de classificação.

6.1 Limitações

O estudo apresenta limitações que circunscrevem suas conclusões. A avaliação restringiu-se a um único conjunto de dados (AGNews)

e a uma única arquitetura (BERT), de modo que a generalização para outros domínios e modelos requer verificação adicional. A análise qualitativa concentrou-se em um subconjunto de 16 instâncias herdadas de Soares [9]; embora representativas dos quatro grupos de homogeneidade, não esgotam a variedade de comportamentos do conjunto completo. Por fim, o *speedup* de treinamento não foi medido diretamente neste trabalho, uma vez que os modelos foram treinados em ambientes distintos, o que inviabiliza uma comparação justa de tempo. Reportou-se, em seu lugar, a redução do conjunto de treinamento, com referência ao ganho de eficiência documentado por Cunha et al. [2].

Adicionalmente, os resultados reportados correspondem a uma única execução por cenário. Como o treinamento de redes neurais apresenta variabilidade entre diferentes inicializações, a confirmação estatística das diferenças observadas ainda depende de múltiplas execuções com sementes distintas e de testes de significância, como o teste de Wilcoxon. Esse passo é necessário antes de qualquer afirmação conclusiva sobre a superioridade de um método em relação ao outro.

6.2 Trabalhos Futuros

Como desdobramentos, propõe-se: (i) estender a avaliação a múltiplos conjuntos de dados e arquiteturas, por exemplo RoBERTa, verificando a robustez do efeito dissociado; (ii) explorar a variação das taxas de redução de redundância (β) e ruído (γ) do biO-IS,

SciTech ERR-Low (Prime time) — instância de teste 5756




Figura 5: Instância de Sci/Tech “Prime time”, incorretamente classificada. A IS homogeneiza a vizinhança (biO-IS, entropia 0,306), mas em torno de um tema distinto do rótulo real, ilustrando um limite do método.

World HIT-High (Baghdad) — controle — instância de teste 1667



Figura 6: Instância de World “Baghdad” (controle). As nuvens são praticamente idênticas nos três cenários, mostrando que a IS preserva vizinhanças já homogêneas.

caracterizando o compromisso entre compactação do espaço e homogeneidade da localidade; (iii) validar estatisticamente a análise exploratória de estabilidade (Seção 5.4) com múltiplas execuções e sementes distintas, confirmando o efeito observado entre regiões; e (iv) avaliar, por meio de estudo com usuários nos moldes de Soares [9], se o aumento de homogeneidade promovido pelo biO-IS se traduz, de fato, em explicações percebidas como mais compreensíveis.

Referências

- [1] Ahmad Bilal, David Ebert, and Bin Lin. 2025. Explainable artificial intelligence for text classification: A survey. *arXiv preprint* (2025).
- [2] Washington Cunha, Leonardo Rocha, and Marcos André Gonçalves. 2025. A noise-oriented and redundancy-aware instance selection framework. *ACM Transactions on Information Systems* 43, 2 (2025), 1–33.
- [3] Washington Cunha, Felipe Viegas, Celso França, Thierson Rosa, Leonardo Rocha, and Marcos André Gonçalves. 2023. An effective, efficient, and scalable confidence-based instance selection framework for transformer-based text classification. In *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval*. ACM.
- [4] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of NAACL-HLT* (2019), 4171–4186.
- [5] Yinhan Liu, Mylène Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. 2019. RoBERTa: A Robustly Optimized BERT Pretraining Approach. *arXiv preprint arXiv:1907.11692*.
- [6] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. 2011. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research* 12 (2011), 2825–2830.
- [7] Yogachandran Rahulamathavan, Misbah Farooq, and Varuna De Silva. 2025. PLEX: Perturbation-free Local Explanations for LLM-Based Text Classification. *arXiv preprint arXiv:2507.10596* (2025).
- [8] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. 2016. “Why Should I Trust You?”: Explaining the Predictions of Any Classifier. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1135–1144.
- [9] Liziane Soares. 2025. *Localidade e explicabilidade na classificação automática de textos com modelos baseados em Transformers*. Master’s thesis. Universidade Federal de Minas Gerais (UFMG). Manuscrito em preparação.
- [10] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, et al. 2020. Transformers: State-of-the-Art Natural Language Processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. 38–45.
- [11] Xiang Zhang, Junbo Zhao, and Yann LeCun. 2015. Character-level convolutional networks for text classification. *Advances in Neural Information Processing Systems (NeurIPS)* 28 (2015).